

Chapter 19 : Training and Deploying TensorFlow Models at Scale

Wilhelmina Arlene Simbolon – 1103223046

Bab terakhir berfokus pada aspek produksi dan skalabilitas sistem Machine Learning. Model yang telah dilatih perlu disajikan dalam bentuk layanan yang dapat digunakan oleh aplikasi lain, misalnya melalui TensorFlow Serving atau platform cloud. Proses ini mencakup penyimpanan model, pembuatan API prediksi, serta pengujian performa inference.

Pemanfaatan hardware akselerator seperti GPU dibahas sebagai cara untuk mempercepat training model berskala besar. Pengelolaan memori GPU, distribusi komputasi, serta penempatan operasi menjadi faktor penting dalam efisiensi sistem. Selain itu, dijelaskan konsep data parallelism dan model parallelism untuk melatih model pada beberapa device secara bersamaan.

TensorFlow Distribution Strategies diperkenalkan sebagai abstraksi untuk mempermudah training terdistribusi tanpa harus mengelola detail komunikasi antar perangkat. Pendekatan ini memungkinkan skalabilitas dari satu mesin hingga cluster besar.

Bab ini menekankan bahwa keberhasilan sistem Machine Learning tidak hanya ditentukan oleh akurasi model, tetapi juga oleh kemampuannya untuk di-deploy, di-maintain, dan diskalakan secara andal di lingkungan nyata.